Kaggle Competition說明

Name : 鄭丞恩
Group : 83
2024/12/1

題目條件、資料結構、原始碼 給ChatGPT

- **給你一個 project 的相關資料 , 然後等一下問你問題** " Overview NTHU DM2023 ISA5810 Lab2 Homework Description In this competition, we provide a dataset which was crawled from Twitter, and we have already labeled the emotion for these tweets by some specific hashtags in the original text. There are 8 classes (or say emotions) in our dataset: anger, anticipation, disgust, fear, sadness, surprise, trust, and joy. You have to clean the data by doing some pre-processing first. Then, apply feature engineering or any other data mining technique you have or haven't learned in the Data Mining course. The final goal is to learn a model that is able to predict the emotion behind each tweet. Evaluation You will be evaluated by comparing your Submission CSV to the ground truth Solution CSV with respect the chosen the Mean F1 Score. This competition is worth 30% of your grade for the DM2023-Lab2-Homework. The scoring will be given according to your place in the Private Leaderboard ranking: Bottom 40%: Get 20% of the score (ie. 20% of 30%) Top 41% - 100%: Get (101-x)% of the score, where x is your ranking in the leaderboard (ie. (101-x)% of 30%) Submission Format Submit a CSV file with your predictions. It should contain two string-type columns: id and emotion. Make sure you include the headers as well id, emotion 0x356d9a, surprise 0x2c7743, surprise 0x2c1eed, surprise 0x2826ea, surprise etc. Data : 4 Files , .json x 1 .csv x 3 data_identification.csv tweet_idsort text_formatidentificationsort 0x28cc61 test 0x29e452 train 0x2b3819 train 0x2db41f test 0x2a2acc train emotion.csv tweet_id emotion 0x3140b1 sadness 0x368b73 disgust 0x296183 anticipation 0x2bd6e1 joy 0x2ee1dd anticipation sampleSubmission.csv id emotion 0x2c7743 surprise 0x2c1eed surprise 0x2826ea surprise 0x356d9a surprise 0x20fd95 surprise code : import json import pandas as pd import numpy as np import nltk import matplotlib.pyplot as plt from collections import Counter from sklearn.feature_extraction.text import TfidfVectorizer from sklearn.model_selection import train_test_split from sklearn.preprocessing import LabelEncoder from sklearn.ensemble import RandomForestClassifier from sklearn.metrics import classification_report data = [] with open('/kaggle/input/dm-2024-isa-5810-lab-2-homework/tweets_DM.json', 'r') as f: for line in f: data.append(json.loads(line)) f.close() emotion = pd.read_csv('/kaggle/input/dm-2024-isa-5810-lab-2-homework/emotion.csv') data_identification = pd.read_csv('/kaggle/input/dm-2024-isa-5810-lab-2-homework/data_identification.csv') df = pd.DataFrame(data) _source = df['_source'].apply(lambda x: x['tweet']) df = pd.DataFrame({ 'tweet_id': _source.apply(lambda x: x['tweet_id']), 'hashtags': _source.apply(lambda x: x['hashtags']), 'text': _source.apply(lambda x: x['text']), }) df = df.merge(data_identification, on='tweet_id', how='left') train_data = df[df['identification'] == 'train'] test_data = df[df['identification'] == 'test'] train_data = train_data.merge(emotion, on='tweet_id', how='left') train_data.drop_duplicates(subset=['text'], keep=False, inplace=True) train_data_sample = train_data.sample(frac=0.3, random_state=42) y_train_data = train_data_sample['emotion'] X_train_data = train_data_sample.drop(['tweet_id', 'emotion', 'identification', 'hashtags'], axis=1) from sklearn.model_selection import train_test_split X_train, X_test, y_train, y_test = train_test_split(X_train_data, y_train_data, test_size=0.2, random_state=42, stratify=y_train_data) tfidf = TfidfVectorizer(max_features=500) X = tfidf.fit_transform(X_train['text']).toarray() X_test = tfidf.transform(X_test['text']) le = LabelEncoder() y = le.fit_transform(y_train) y_test = le.transform(y_test) clf = RandomForestClassifier() clf.fit(X, y) y_pred = clf.predict(X_test) from sklearn.metrics import accuracy_score accuracy_score(y_test, y_pred) X_test_data = test_data.drop(['tweet_id', 'identification', 'hashtags'], axis=1) X_test_data = tfidf.transform(X_test_data['text']).toarray() y_test_pred = clf.predict(X_test_data) y_pred_labels = le.inverse_transform(y_test_pred) y_pred_labels submission = pd.DataFrame({ 'tweet_id': test_data['tweet_id'], 'identification': y_pred_labels }) submission.to_csv('/kaggle/working/submission.csv') "

針對原始碼，寫下註解

以下是按照不同階段添加詳細註解的程式碼：

python 複製程式碼

```python
# 引入必要的庫
import json
import pandas as pd
import numpy as np
import nltk
import matplotlib.pyplot as plt
from collections import Counter
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, accuracy_score

# ======== 資料讀取與整理 ========
# 1. 讀取 JSON 格式的推文數據
data = []
with open('/kaggle/input/dm-2024-isa-5810-lab-2-homework/tweets_DM.json', 'r') as f:
    for line in f:
        data.append(json.loads(line))
```

```python
# 4. 合併情緒標籤到訓練資料中
train_data = train_data.merge(emotion, on='tweet_id', how='left')

# 5. 移除訓練集中重複的文本
train_data.drop_duplicates(subset=['text'], keep=False, inplace=True)

# ======== 訓練數據準備 ========
# 1. 抽取部分訓練數據（30% 抽樣）
train_data_sample = train_data.sample(frac=0.3, random_state=42)

# 2. 提取目標變數（情緒）和特徵變數（文本）
y_train_data = train_data_sample['emotion']
X_train_data = train_data_sample.drop(['tweet_id', 'emotion', 'identification', 'hashtags'

# 3. 訓練集與測試集劃分（分層抽樣確保類別分佈一致）
X_train, X_test, y_train, y_test = train_test_split(
    X_train_data, y_train_data, test_size=0.2, random_state=42, stratify=y_train_data
)

# ======== 文本特徵轉換 ========
# 1. 使用 TF-IDF 將文本轉換為數值特徵
tfidf = TfidfVectorizer(max_features=500)
X = tfidf.fit_transform(X_train['text']).toarray()
X_test = tfidf.transform(X_test['text'])
```

萃取註解，了解程式結構

把註解都萃取出來，用 markdown, 統一用程式碼 方式呈現

2/2

markdown　　複製程式碼

```
# 程式碼註解萃取

```python
# ======== 資料讀取與整理 ========
# 1. 讀取 JSON 格式的推文數據
# 2. 讀取其他 CSV 文件

# ======== 數據處理 ========
# 1. 從 JSON 數據提取 tweet_id, hashtags, 和文本內容
# 2. 合併資料集標籤 (train/test)
# 3. 將資料分為訓練集和測試集
# 4. 合併情緒標籤到訓練資料中
# 5. 移除訓練集中重複的文本

# ======== 訓練數據準備 ========
# 1. 抽取部分訓練數據 ( 30% 抽樣 )
# 2. 提取目標變數 (情緒) 和特徵變數 (文本)
# 3. 訓練集與測試集劃分 (分層抽樣確保類別分佈一致)

# ======== 文本特徵轉換 ========
```

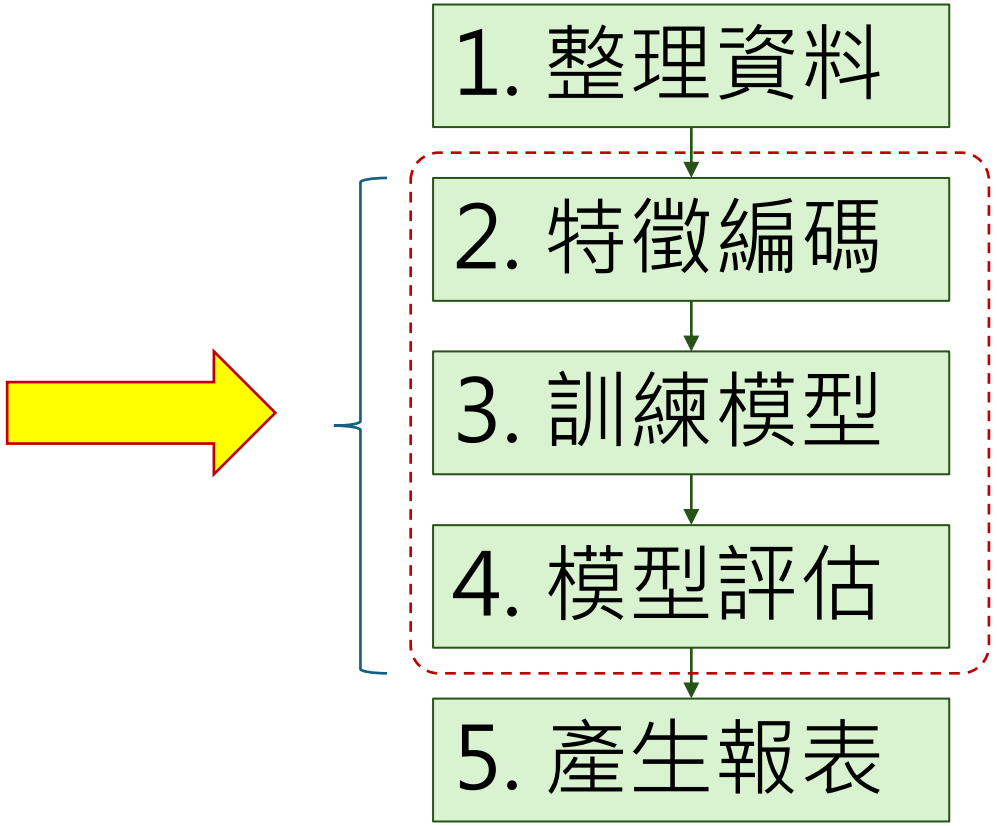
```

重點在這，有哪些選擇適合？

2. 特徵編碼

3. 訓練模型

問ChatGPT

ChatGP說明，但怎樣管理(安排)還是得知道

2. 特徵編碼 → 可能有 n 個

3. 訓練模型 → 可能有 k 個

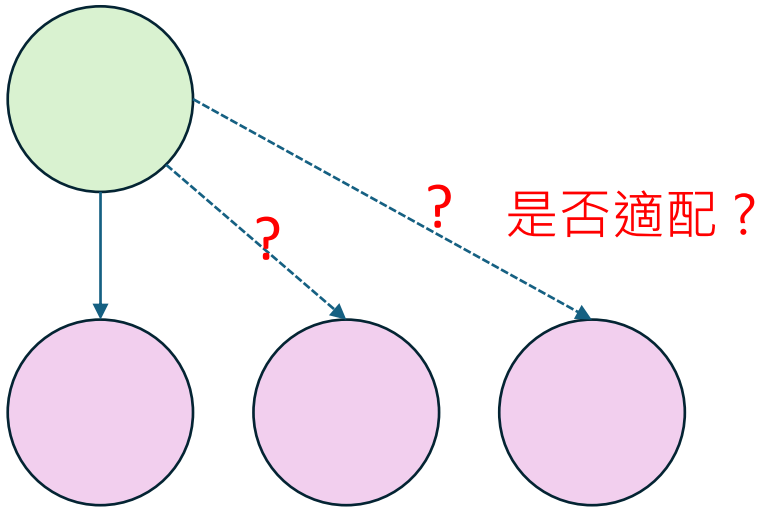

適配？ 問ChatGPT

為何使用 TF-IDF

1. **計算詞語的重要性**
   - TF-IDF（Term Frequency-Inverse Document Frequency）是一種統計方法，能衡量單詞在文檔中的重要性。
   - **TF（詞頻）**：詞在文檔中出現的頻率，衡量詞在該文檔中的重要程度。
   - **IDF（逆文檔頻率）**：考慮詞在整個語料庫中的稀有程度，常見詞（例如 "the", "is"）權重降低，稀有詞權重提高。
2. **適合處理短文本數據**
   - 推文數據通常較短且具有稀疏性，TF-IDF 可以幫助突顯具有區別性的單詞，而非只關注常見詞。
3. **簡單且高效**
   - 生成的向量維度可以由 `max_features` 控制，計算相對高效，適合在基礎情感分析中作為文本表示。

可替代方法

1. **詞嵌入方法**
   - 將詞轉換為固定維度的數值向量，保留詞之間的語義關係，效果通常優於 TF-IDF，適合更複雜的情感分析。

   (1) Word2Vec
   - 訓練或使用預訓練的詞嵌入模型（如 Google 的 Word2Vec）。
   - 缺點：對短文本表現有限，因為它忽略詞序與上下文關係。

用老闆的思維發問
為何非他不可？
編碼**為何要用TF-IDF**？

底下的人必須要**解釋原因**
以及想出**可替代方法**

編碼方法問完後如法炮製
模型問題也問一遍

了解，請問除了 random forest 之外有其他方法嗎？

當然有！除了隨機森林（Random Forest），還有許多其他模型可以用於情緒分類，根據數據特性、計算資源與任務需求選擇合適的方法。以下分類說明：

---

1. 傳統機器學習模型

(1) 支持向量機 (SVM)

- 特點
  - 適合高維稀疏數據（如 TF-IDF 向量）。
  - 通過選擇合適的核函數（如線性核或 RBF 核），能很好地處理非線性數據。
- 適用場景
  - 資料量中等，特徵維度較高的文本分類問題。
- 注意事項
  - 訓練時間較長，尤其是當樣本數量較多時。

(2) 邏輯回歸 (Logistic Regression)

- 特點
  - 用於二分類或多分類任務，簡單高效，計算資源需求低。
  - 通過正則化項（L1 或 L2）可避免過擬合。
- 適用場景
  - 標籤數量較少（如二元情緒分類），[illegible]數據規模小。

用老闆的思維發問
為何非**隨機森林**不可？
模型除了**隨機森林**還有其他?

底下的人必須要**解釋原因**
以及列出**其他模型**

Chatgpt給一堆編碼和模型
身為老闆還是要小心被騙

2. 特徵編碼 → 可能有 n 個

3. 訓練模型 → 可能有 k 個

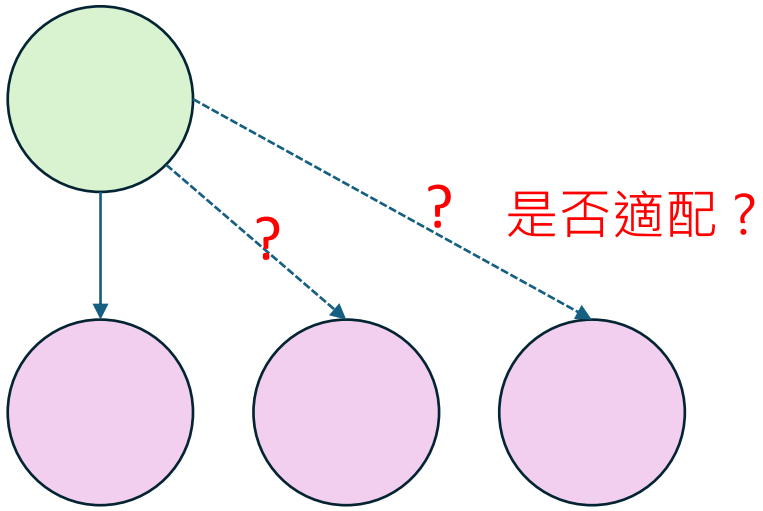

特徵編碼 跟 訓練模型
之間是否有搭配問題？

→ 叫底下的人去整理表格出來

關鍵來了，要懂得問

- 假設依照上面介紹的內容，在相同資料的前提之下，特徵轉換 和 採用的模型 是否有特定的搭配關係？

假設依照上面介紹的內容，在相同資料的前提之下，特徵轉換 和 採用的模型 是否有特定的搭配關係？

關鍵問題

Bingo !

是的 在特徵轉換和採用模型之間，確實存在一定的搭配關係。不同的特徵表示方式可能會影響模型的效果，因為每種模型對數據的需求與表現方式有所不同。以下根據特徵轉換與模型的匹配性進行分析：

---

1. 傳統特徵轉換方法與模型搭配

(1) TF-IDF

- 適合模型：
  - 支持向量機 (SVM)：高維稀疏數據表現良好，尤其是線性分類器。
  - 隨機森林 (Random Forest)：對特徵選擇不敏感，但在高維特徵下仍表現穩定。
  - 梯度提升樹 (如 XGBoost, LightGBM)：適合處理稀疏特徵數據，且能自動選擇重要特徵。
  - 邏輯回歸 (Logistic Regression)：適用於線性分類，對高維數據有不錯的效果。
- 不適合模型：
  - 深度學習模型（如 CNN, RNN, Transformer）：這些模型需要更語義化的特徵表示（如詞嵌入），TF-IDF 無法捕捉上下文信息。

(2) Bag of Words (詞袋模型)

- 適合模型：
  - 與 TF-IDF 相似，適合 SVM、隨機森林、邏輯回歸。
  - 特徵簡單，對文本語序和語義無要求，適合基礎任務有效。

模型與特徵轉換的搭配總結

模型與特徵轉換的搭配總結

模型	推薦特徵轉換	不推薦特徵轉換	適用場景
隨機森林 (Random Forest)	TF-IDF, Bag of Words, Word2Vec 平均向量	Contextual Embedding (需降維處理)	稀疏或非線性特徵數據，模型穩定性需求高。
支持向量機 (SVM)	TF-IDF, Bag of Words, Word2Vec 平均向量	One-Hot Encoding, Raw Text	高維稀疏特徵，分類邊界清晰。
邏輯回歸 (Logistic Regression)	TF-IDF, Bag of Words, One-Hot Encoding	Contextual Embedding	特徵數據規模小，線性分類需求。
梯度提升樹 (XGBoost, LightGBM)	TF-IDF, Word2Vec 平均向量	Contextual Embedding (需降維處理)	特徵豐富、需要高精準度的分類或迴歸任務。
Bagging (如隨機森林)	TF-IDF, Bag of Words, Word2Vec 平均向量	Contextual Embedding	適合高維稀疏數據，降低模型方差。
Boosting (XGBoost, LightGBM)	TF-IDF, Word2Vec 平均向量	Contextual Embedding	特徵豐富且密集，對精準度需求高的分類任務。
AdaBoost	TF-IDF, Bag of Words, Word2Vec 平均向量	Contextual Embedding	適合小型數據集，對難分類樣本有強適應性。
卷積神經網絡 (CNN)	Word2Vec, FastText, GloVe	TF-IDF, Bag of Words	文本局部特徵提取，適合短文本或固定長度文本。
循環神經網絡 (RNN, LSTM)	Word2Vec, GloVe, FastText, Contextual Embedding	TF-IDF, Bag of Words	捕捉上下文關係，處理長文本和序列數據。
Transformer (BERT)	Contextual Embedding	TF-IDF, Bag of Words	高語義需求的情緒分類或上下文語義理解任務。

還等甚麼？
叫底下的人把這**搭配組合**做表格出來

搭配組合配方出來了，接下來就是生產問題

生產最重視：**效率**跟**成本**

關鍵生產要素：效率跟成本

- 效率：配方(編碼+模型) 的 → 準確性Accuracy
- 成本：最快生產完成的關鍵條件 → 用GPU能否加速

於是我寫了五支程式

- 1. TF-IDF + Randon_forest (助教提供 , 有稍微改一些)
- 2. TF-IDF + Boosting (XGBoost) w/GPU
- 3. Word2Vec + 隨機森林
- 4. Word2Vec + CNN w/GPU
- 5. BERT 嵌入 + Transformer w/GPU

生產之前就把期望值預估好

方法	特徵工程	模型	準確率預估	優勢	劣勢	GPU 支援
TF-IDF + 隨機森林	稀疏特徵表示，詞頻與逆文檔頻率權重	隨機森林	75%-82%	模型穩定性強，對噪聲和高維數據不敏感	無法處理非線性模式，對語義信息利用不足	不支持
TF-IDF + Boosting	稀疏特徵表示，詞頻與逆文檔頻率權重	XGBoost 或 LightGBM	78%-85%	擅長處理稀疏特徵，對錯分樣本有良好適應能力	訓練成本略高，需調參以達到最佳效果	支持（顯著加速，適合大數據集）
Word2Vec + 隨機森林	詞嵌入，計算句向量平均值	隨機森林	72%-80%	能結合詞嵌入語義特徵，提升語義捕捉能力	詞嵌入需預處理，隨機森林對非線性語義的處理有限	不支持
Word2Vec + CNN	詞嵌入，保留語序	卷積神經網絡	75%-85%	捕捉局部語義特徵，對短文本效果佳	訓練需較多資源，對長文本效果有限	支持（顯著加速）
BERT 嵌入 + Transformer	上下文語義嵌入，保留全局語義	預訓練 BERT 模型	85%-90%	能捕捉上下文語義，分類準確率最高	訓練和推理成本高，需要大量數據和資源支持	支持（必要，否則速慢）

效率預估期望值

成本預估期望值

整理好全部方法資料
準確率、使用範圍(優/劣勢)、GPU支援情況

方法	特徵工程	模型	準確率預估	優勢	劣勢	GPU 支援
TF-IDF + 隨機森林	稀疏特徵表示，詞頻與逆文檔頻率權重	隨機森林	75%-82%	模型穩定性強，對噪聲和高維數據不敏感	無法處理非線性模式，對語義信息利用不足	不支持
TF-IDF + Boosting	稀疏特徵表示，詞頻與逆文檔頻率權重	XGBoost 或 LightGBM	78%-85%	擅長處理稀疏特徵，對錯分樣本有良好適應能力	訓練成本略高，需調參以達到最佳效果	支持（顯著加速，適合大數據集）
Word2Vec + 隨機森林	詞嵌入，計算句向量平均值	隨機森林	72%-80%	能結合詞嵌入語義特徵，提升語義捕捉能力	詞嵌入需預處理，隨機森林對非線性語義的處理有限	不支持
Word2Vec + CNN	詞嵌入，保留語序	卷積神經網絡	75%-85%	捕捉局部語義特徵，對短文本效果佳	訓練需較多資源，對長文本效果有限	支持（顯著加速）
BERT 嵌入 + Transformer	上下文語義嵌入，保留全局語義	預訓練 BERT 模型	85%-90%	能捕捉上下文語義，分類準確率最高	訓練和推理成本高，需要大量數據和資源支持	支持（必要，否則速慢）

把這五個當成 prompt 條件

背景資料提供給LLM

- 專案目的
- 資料檔案名稱、格式(少量取樣)

<<第一份程式碼，由助教提供的那一份>>

產生新的程式碼
(整理資料、編碼、模型訓練、模型評估)

把這一段 code , 保留開頭資料處理的部分 , 然後把 中間改成

Word2Vec + CNN 方法

"

<<第一份程式碼, 由助教提供的那一份>>

"

Code 執行環境有GPU , 請針對 GPU環境優化程式碼

最後生成 **<code1>**

產生新的程式碼
(分析部分)

在變數不變的情況下 , 延續這 code

"

<code1>

"

在變數不變的情況下，生成程式碼 的 **分析部分** :

1. 列出混淆矩陣　2. 畫出混淆矩陣

3.印出 Classification Report　4. 印出 Accuracy

這 4 個項目中間用 print(“\n” , “----” , “\n”) 分隔

完成程式碼撰寫

準確率紀錄：

- Accuracy: 0.4586
- Accuracy: 0.4580

3. Word2Vec + 隨機森林 Draft saved

File Edit View Run Settings Add-ons Help

Run All Code

```python
# 引入必要的庫
import json
import pandas as pd
import numpy as np
import nltk
from nltk.tokenize import word_tokenize
from gensim.models import Word2Vec
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, accuracy_score

# 確保 NLTK 資源可用
nltk.download('punkt')

# ======== 資料讀取與整理 ========
# 1. 讀取 JSON 格式的推文數據
data = []
with open('/kaggle/input/dm-2024-isa-5810-lab-2-homework/tweets_DM.json', 'r') as f:
    for line in f:
        data.append(json.loads(line))
f.close()

# 2. 讀取其他 CSV 文件
emotion = pd.read_csv('/kaggle/input/dm-2024-isa-5810-lab-2-homework/emotion.csv')
data_identification = pd.read_csv('/kaggle/input/dm-2024-isa-5810-lab-2-homework/data_identification.csv')

# ======== 數據處理 ========
# 1. 從 JSON 數據提取 tweet_id, hashtags, 和文本內容
df = pd.DataFrame(data)
_source = df['_source'].apply(lambda x: x['tweet'])
df = pd.DataFrame({
    'tweet_id': _source.apply(lambda x: x['tweet_id']),
    'hashtags': _source.apply(lambda x: x['hashtags']),
    'text': _source.apply(lambda x: x['text']),
})

# 2. 合併資料集標籤 (train/test)
df = df.merge(data_identification, on='tweet_id', how='left')
```

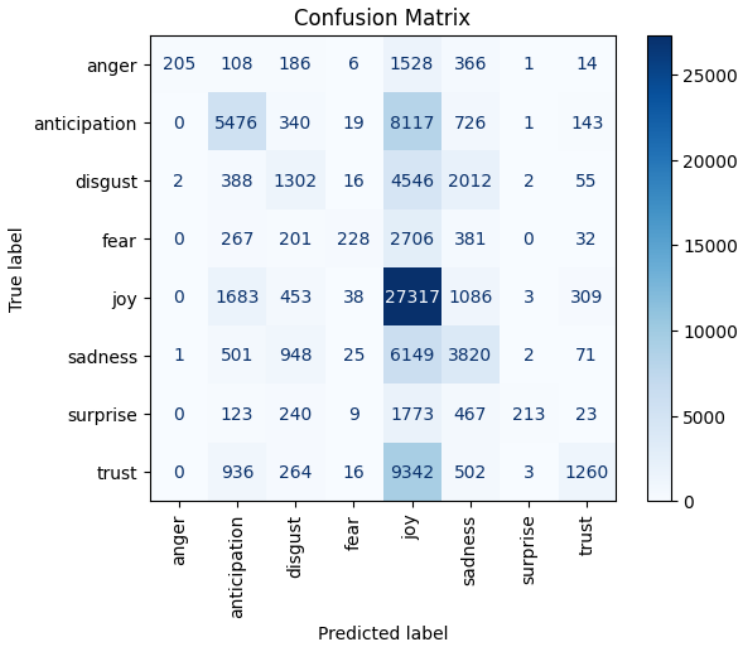


```
----

Confusion Matrix:
[[  205   108   186     6  1528   366     1    14]
 [    0  5476   340    19  8117   726     1   143]
 [    2   388  1302    16  4546  2012     2    55]
 [    0   267   201   228  2706   381     0    32]
 [    0  1683   453    38 27317  1086     3   309]
 [    1   501   948    25  6149  3820     2    71]
 [    0   123   240     9  1773   467   213    23]
 [    0   936   264    16  9342   502     3  1260]]

----
```

解決造成模型準確率偏低的雜訊問題

執行程式碼之後結果比較

方法	特徵工程	模型	準確率預估	採用原始資料	GPU 支援
TF-IDF + 隨機森林	稀疏特徵表示，詞頻與逆文檔頻率權重	隨機森林	75%-82%	0.4808	No
TF-IDF + Boosting	稀疏特徵表示，詞頻與逆文檔頻率權重	XGBoost 或 LightGBM	78%-85%	0.4780	GPU T4 x 2
Word2Vec + 隨機森林	詞嵌入，計算句向量平均值	隨機森林	72%-80%	0.4586	No
Word2Vec + CNN	詞嵌入，保留語序	卷積神經網絡	75%-85%	0.5514	GPU T4 x 2
BERT 嵌入 + Transformer	上下文語義嵌入，保留全局語義	預訓練 BERT 模型	85%-90%	0.6439	GPU T4 x 2

ノイズ

Noise

雜訊

ノイズ
Noise
雜訊

誤判為雜訊 → → 加強訊號

Recycle it！

確定是雜訊 →

Just Delete it！

看一下 data

emojis (絵文字)

Tag : <LH>

```python
import json

data = []
with open('/kaggle/input/dm-2024-isa-5810-lab-2-homework/tweets_DM.json', 'r') as f:
    for line in f:
        data.append(json.loads(line))

# 獲取前 2000 筆資料
first_2000_entries = data[:2000]

# 列印前 2000 筆資料
for entry in first_2000_entries:
    print(entry)
```


```
{'_score': 391, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': ['Snapchat'], 'tweet_id': '0x376b20', 'text': 'People who post "add me on #Snapchat" must be dehydrated. Cuz man.... that\'s <LH>'}}, '_crawl
date': '2015-05-23 11:42:47', '_type': 'tweets'}
{'_score': 433, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': ['freepress', 'TrumpLegacy', 'CNN'], 'tweet_id': '0x2d5350', 'text': '@brianklaas As we see, Trump is dangerous to #freepress around the worl
d. What a <LH> <LH> #TrumpLegacy.  #CNN'}}, '_crawldate': '2016-01-28 04:52:09', '_type': 'tweets'}
{'_score': 232, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': ['bibleverse'], 'tweet_id': '0x28b412', 'text': 'Confident of your obedience, I write to you, knowing that you will do even more than I ask.
(Philemon 1:21) 3/4 #bibleverse <LH> <LH>'}}, '_crawldate': '2017-12-25 04:39:20', '_type': 'tweets'}
{'_score': 376, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': [], 'tweet_id': '0x1cd5b0', 'text': 'Now ISSA is stalking Tasha 😩😩😩 <LH>'}}, '_crawldate': '2016-01-24 23:53:05', '_type': 'tweets'}
{'_score': 989, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': [], 'tweet_id': '0x2de201', text': '"Trust is not the same as faith. A friend is someone you trust. Putting faith in anyone is a mistake." ~
Christopher Hitchens <LH> <LH>'}}, '_crawldate': '2016-01-08 17:18:59', '_type': 'tweets'}
{'_score': 120, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': ['authentic', 'LaughOutLoud'], 'tweet_id': '0x1d755c', 'text': '@RISKshow @TheKevinAllison Thx for the BEST TIME tonight. What stories! Heart
breakingly <LH> #authentic #LaughOutLoud good!!'}}, '_crawldate': '2015-06-11 04:44:05', '_type': 'tweets'}
{'_score': 1021, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': [], 'tweet_id': '0x2c91a8', 'text': 'Still waiting on those supplies Liscus. <LH>'}}, '_crawldate': '2015-08-18 02:30:07', '_type': 'tweet
s'}
{'_score': 481, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': [], 'tweet_id': '0x368e95', 'text': 'Love knows no gender. 😢😭 <LH>'}}, '_crawldate': '2015-08-20 14:31:27', '_type': 'tweets'}
{'_score': 827, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': ['LeagueCup'], 'tweet_id': '0x249c0c', 'text': '@DStvNgCare @DStvNg More highlights are being shown than actual sports! Who watches triathlon
highlights anyway? <LH> #LeagueCup'}}, '_crawldate': '2016-04-18 13:01:02', '_type': 'tweets'}
{'_score': 66, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': ['materialism', 'money', 'possessions'], 'tweet_id': '0x218443', 'text': 'When do you have enough ? When are you satisfied ? Is you goal reall
y all about money ?  #materialism #money #possessions <LH>'}}, '_crawldate': '2015-09-09 09:22:55', '_type': 'tweets'}
{'_score': 631, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': ['SSM', 'gender', 'diversity'], 'tweet_id': '0x359db9', 'text': 'The #SSM debate; <LH> (a manufactured fantasy used to distract the ignorant
masses from their mundane lives) V #gender #diversity (a m.....'}}, '_crawldate': '2016-08-05 21:15:36', '_type': 'tweets'}
{'_score': 839, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': [], 'tweet_id': '0x23b037', 'text': "I love suffering 🙃🙃 I love when valium does nothing to help 🙃🙃 I love when my doctors say that the
y've done all they can 🙃🙃 <LH>"}}, '_crawldate': '2016-01-28 08:11:22', '_type': 'tweets'}
{'_score': 560, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': ['Pissed'], 'tweet_id': '0x1fde89', 'text': 'Can someone tell my why my feeds scroll back to the same 30 tweets that I saw 1 min ago? #Pisse
d!'}}, '_crawldate': '2016-01-26 22:09:45', '_type': 'tweets'}
{'_score': 887, '_index': 'hashtag_tweets', '_source': {'tweet': {'hashtags': ['justgradstudentthings', 'ecology'], 'tweet_id': '0x37a0a9', 'text': 'You know you research butterflies when predictive text autocorrects "b
ut" to "butterfly" #justgradstudentthings #ecology <LH>'}}, '_crawldate': '2015-08-11 16:22:15', '_type': 'tweets'}
```

我又寫了程式：查html tag數量

```python
import json
from collections import Counter
from bs4 import BeautifulSoup
import pandas as pd

# 初始化資料列表
data = []

# 讀取 JSON 文件
with open('/kaggle/input/dm-2024-isa-5810-lab-2-homework/tweets_DM.json', 'r') as f:
    for line in f:
        data.append(json.loads(line))

# 初始化計數器
tag_counter = Counter()

# 遍歷每條推文
for entry in data:
    tweet_text = entry['_source']['tweet']['text']
    # 使用 BeautifulSoup 解析推文文本
    soup = BeautifulSoup(tweet_text, 'html.parser')
    # 提取所有標籤
    tags = [tag.name for tag in soup.find_all()]
    # 更新計數器
    tag_counter.update(tags)

# 將計數結果轉換為 DataFrame
df_tags = pd.DataFrame(tag_counter.items(), columns=['Tag', 'Count'])

# 根據出現次數進行排序
df_tags = df_tags.sort_values(by='Count', ascending=False).reset_index(drop=True)

# 顯示結果
# print(df_tags)
```

```python
print(df_tags)
```

	Tag	Count
0	lh	2296492

搞半天只有 <lh>
但數量有 2,296,492 個

沒用

Just Delete it！

我又寫了程式：查emoji 數量 & 分布

```python
import json
import regex
import collections
import matplotlib.pyplot as plt

# 定義從文本中提取表情符號的函數
def extract_emojis(text):
    """從給定的文本中提取所有表情符號。"""
    emoji_list = []
    data = regex.findall(r'\X', text)
    for word in data:
        if any(char in emoji.EMOJI_DATA for char in word):
            emoji_list.append(word)
    return emoji_list

# 讀取 JSON 檔案並解析為列表
data = []
with open('/kaggle/input/dm-2024-isa-5810-lab-2-homework/tweets_DM.json', 'r') as f:
    for line in f:
        data.append(json.loads(line))

# 提取所有推文中的表情符號
all_emojis = []
for entry in data:
    tweet_text = entry['_source']['tweet']['text']
    emojis_in_tweet = extract_emojis(tweet_text)
    all_emojis.extend(emojis_in_tweet)

# 計算每個表情符號的出現次數
emoji_counter = collections.Counter(all_emojis)

# 取得出現頻率最高的前 100 個表情符號
top_500_emojis = emoji_counter.most_common(500)

# 分離表情符號和對應的計數
emojis, counts = zip(*top_500_emojis)

# 設定圖表大小
plt.figure(figsize=(15, 10))

# 繪製直方圖
```

```python
[7]: top_500_emojis

[7]: [('😂', 50998),
      ('❤️', 41168),
      ('😍', 38386),
      ('😭', 24660),
      ('❤', 18707),
      ('😊', 17003),
      ('🙏', 16446),
      ('😘', 13809),
      ('💕', 12666),
      ('🔥', 12449),
      ('😩', 10466),
      ('😉', 9677),
      ('💯', 9318),
      ('💙', 8911),
      ('😁', 8832),
      ('😜', 8106),
      ('👬', 7403),
      ('🙏', 7284),
      ('👍', 7284),
      ('🙏', 7262),
      ('✨', 7186),
      ('💜', 7086),
      ('😇', 7051),
      ('👏', 7017),
      ('😋', 6712),
      ('😎', 6620),
      ('💔', 6611),
```

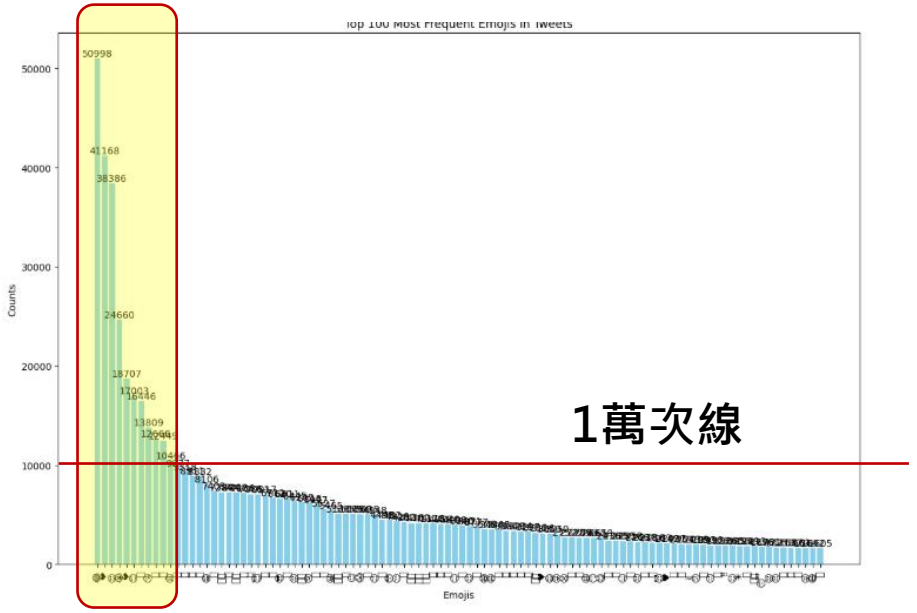

高頻群體
高頻使用這些emoji可以解釋為有明顯情感
在模型當中可以視為具有明顯特徵

Recycle it！

高頻群體處理方式

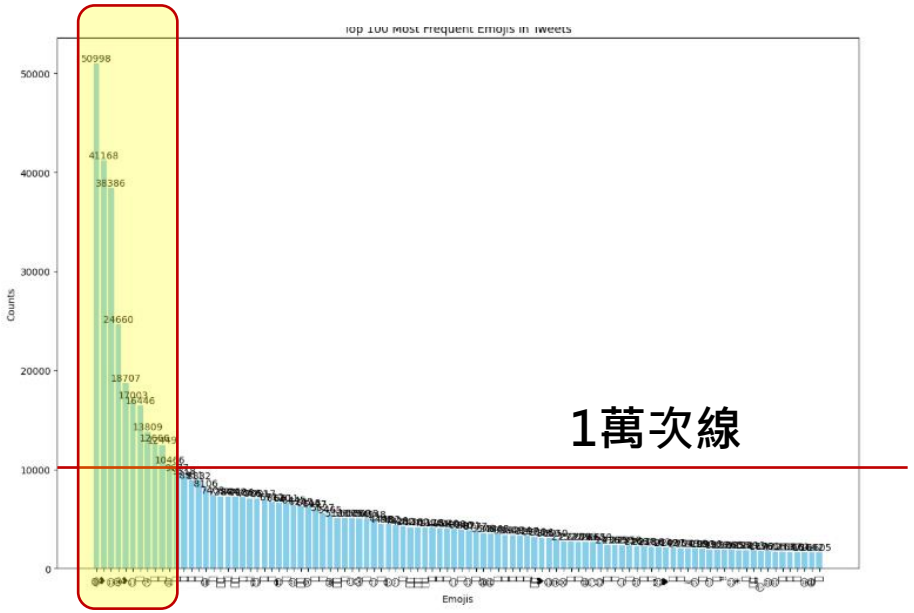

高頻群體
高頻使用這些emoji可以解釋為有明顯情感
在模型當中可以視為具有明顯特徵

Recycle it !

加強訊號

讓特徵更明顯

特徵強化&保留

讓特徵更明顯

特徵強化

Emoji	英文含義	單詞
😂	Face with Tears of Joy	[joy]
💗	Red Heart	[love]
😍	Smiling Face with Heart-Eyes	[love]
😭	Loudly Crying Face	[cry]
💗	Red Heart	[love]
😊	Smiling Face with Smiling Eyes	[happy]
🙏	Folded Hands	[pray]
😘	Face Blowing a Kiss	[kiss]
💕	Two Hearts	[love]
🔥	Fire	[fire]
😩	Weary Face	[weary]
🤔	Thinking Face	[think]
💯	Hundred Points	[perfect]
💙	Blue Heart	[loyalty]
🙄	Face with Rolling Eyes	[annoyed]
😁	Beaming Face with Smiling Eyes	[happy]
🙌	Raising Hands	[celebrate]
🙏	Folded Hands: Medium-Dark Skin Tone	[pray]
👍	Thumbs Up	[approve]
🙏	Folded Hands: Medium Skin Tone	[pray]

做成字典

- 把超過1萬次左右的emoji納入字典，當作過濾器做轉換用途。

特徵保留

```
emoji_dict = {
    '😂': '[joy]',
    '❤️': '[love]',
    '😍': '[love]',
    '😭': '[cry]',
    '💚': '[love]',
    '😊': '[happy]',
    '🙏': '[pray]',
    '😘': '[kiss]',
    '💖': '[love]',
    '🔥': '[fire]',
    '😩': '[weary]',
    '🤔': '[think]',
    '💯': '[perfect]',
    '💙': '[love]',
    '🙄': '[annoyed]',
    '😁': '[happy]',
    '🙌': '[celebrate]',
    '🙏': '[pray]',
    '👍': '[approve]',
    '🙏': '[pray]'
}
```

結果...

方法	特徵工程	模型	準確率預估	採用原始資料	雜訊過濾後	GPU 支援
TF-IDF + 隨機森林	稀疏特徵表示，詞頻與逆文檔頻率權重	隨機森林	75%-82%	0.4808	0.4708	No
TF-IDF + Boosting	稀疏特徵表示，詞頻與逆文檔頻率權重	XGBoost 或 LightGBM	78%-85%	0.4780	0.4675	GPU T4 x 2
Word2Vec + 隨機森林	詞嵌入，計算句向量平均值	隨機森林	72%-80%	0.4586	0.4566	No
Word2Vec + CNN	詞嵌入，保留語序	卷積神經網絡	75%-85%	0.5514	0.5312	GPU T4 x 2
BERT 嵌入 + Transformer	上下文語義嵌入，保留全局語義	預訓練 BERT 模型	85%-90%	0.6439	0.6294	GPU T4 x 2

目前最好成績

Submissions

Select up to 2 submissions that will count towards your final leaderboard score. If less than 2 are selected, Kaggle will automatically select from your best scoring submissions. Learn More

0/2

Auto-selection candidates

All | Successful | Selected | Errors

Recent

Submission and Description	Public Score	Select
1. TF-IDF + Random_forest - Version 5 Complete · 3d ago · Notebook 1. TF-IDF + Random_forest | Version 5	0.34984	☐
4. Word2Vec + CNN (GPU) - Version 2 Complete · 4d ago · Notebook 4. Word2Vec + CNN (GPU) | Version 2	0.40157	☐
1. TF-IDF + Random_forest - Version 3 Complete · 5d ago · Notebook 1. TF-IDF + Random_forest | Version 3	0.31825	☐

目前最佳排名：44！

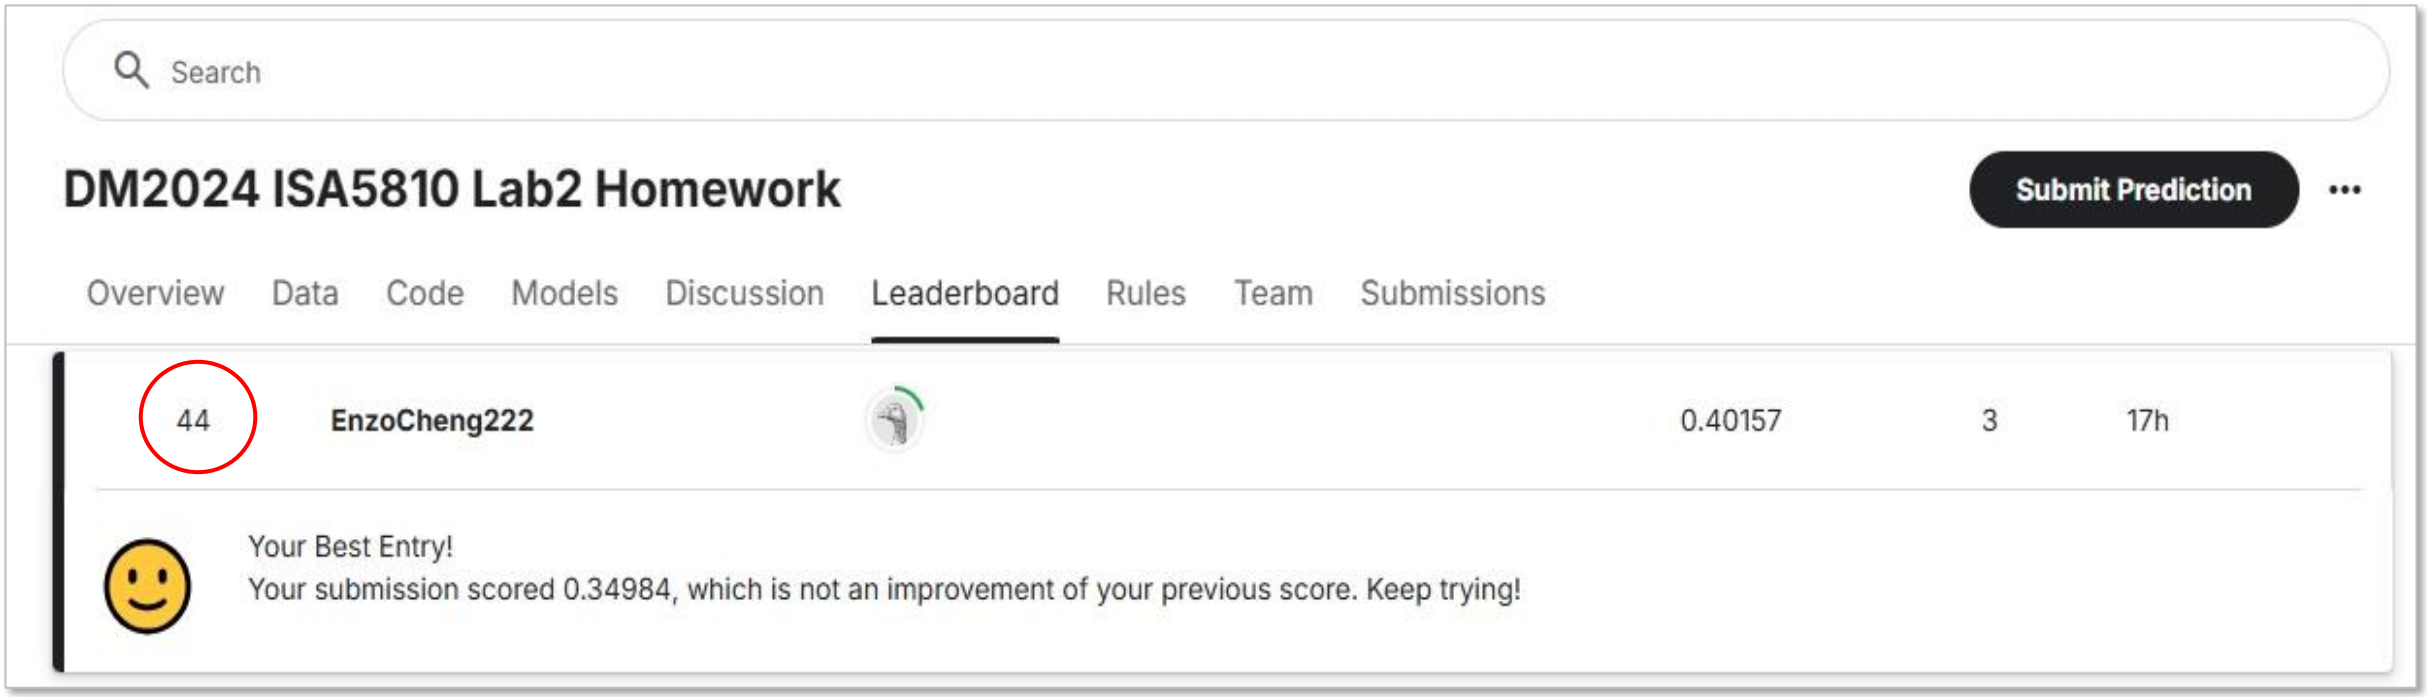
Search
DM2024 ISA5810 Lab2 Homework
Submit Prediction
Overview
Data
Code
Models
Discussion
Leaderboard
Rules
Team
Submissions
44
EnzoCheng222
0.40157
3
17h
Your Best Entry!
Your submission scored 0.34984, which is not an improvement of your previous score. Keep trying!